

LLM-тестирование: полная шпаргалка для QA Engineer

Вопрос: «Чем тестирование ИИ отличается от обычного?» Главное отличие: детерминизм vs вероятность В обычном тестировании: кнопка X → всегда Y. В LLM: один вопрос → много вариантов ответа. Нельзя проверять точное совпадение текста. Проверяем не модель, а систему в целом: • RAG: модель ищет ответы в базе знаний • Agent: выполняет задачи с инструментами • Structured Output: текст → JSON Аналогия для ответа на собеседовании: Модель — это двигатель на стенде (сырая мощность). Система — автомобиль на дороге (тест-драйв с нашими промптами и данными).	Вопрос: «Как оценивать качество LLM-ответов?» Фреймворк: Три столпа качества 1. Релевантность (Relevance) Ответ действительно помогает решить задачу пользователя? Не просто красивый, а полезный. Отсекаем water-ответы. 2. Достоверность (Faithfulness) Ответ строго по фактам из контекста. Модель не должна выдумывать. Если в базе нет информации — ответ: «я не знаю». Это ключ к борьбе с галлюцинациями. 3. Точность контекста (Context Precision) Качество данных, которые нашла RAG-	Вопрос: «Как бороться с галлюцинациями?» Ответ должен звучать уверенно: Шаг 1. Правильная терминология Говорите «достоверность» или «обоснованность» (faithfulness). Покажите, что знаете термин. Шаг 2. RAG как решение RAG-архитектура ограничивает модель, заставляя её опираться на проверенные корпоративные данные, а не на свои «знания» (которые могут быть ложными). Шаг 3. LLM-as-a-Judge Автоматизируем проверку: сильная модель
LLM-as-a-Judge: как работает на практике Сильная модель-судья получает на вход: ① Вопрос пользователя ② Ответ тестируемой системы ③ Исходный контекст (документы из RAG) → Выносит вердикт: релевантно ли? достоверно ли? точен ли контекст? Судебная аналогия: судья проверяет улики (контекст), сверяет с показаниями (ответ) и выносит заключение — всё ли сходится.	Структура ответа на самые частые вопросы Как ответить на «Чем отличается тестирование ИИ?» 1. Ключевое различие: детерминизм → вероятность 2. Аналогия: двигатель (модель) vs автомобиль (система) 3. Предложите фреймворк из 3 столпов как готовый инструмент оценки 4. Вывод: в мире ИИ проверяем смысл, а не слова Как ответить на «Как бороться с галлюцинациями?» 1. Термин: достоверность / обоснованность 2. RAG ограничивает модель корпоративными данными 3. LLM-as-a-Judge автоматизирует проверку 4. Измеряем качество метриками, а не на глаз	Итоговая шпаргалка: 5 пунктов 1. Фокус на системе, а не на модели Мы тестируем всё приложение целиком, а не только LLM в вакууме. 2. Мыслим вероятностями Один вопрос = много правильных ответов. 3. Используем фреймворк из 3 столпов Relevance + Faithfulness + Context Precision 4. Знаем, как автоматизировать оценку LLM-as-a-Judge — масштабируемый метод. 5. Роль QA стала стратегической Мы не просто ищем баги. Мы хранили качества ИИ в бизнес-контексте.