

LLM Testing – Shpargalka dlya QA Engineer

1. Smena paradigmy: Determinizm -> Veroyatnost

Bylo (obychnoe testirovanie):

Knopka X -> vseгда rezultat Y

Tochnoe sovpadenie teksta

Stalo (LLM testirovanie):

Ta zhe mysl -> desyatki formulirovok

Proveryaem namerenie, a ne text

Analogiya dlya sobesedovaniya:

Dvigatel (model) na stende

vs Avtomobil (sistema) - test-drayv

3 populyarnykh arhitektury:

1. RAG - model-bibliotekar

2. Agent - II-menedzher + instrumenty

3. Structured output -> JSON

2. Tri stolpa kachestva (freymvork)

Relevance (Relevantnost)

Otvet pomagaet reshit zadachu?

Otsekaem krasivyy, no bespoleznyj

Faithfulness (Dostovernost)

Otvet strogo po predostavlennym

dannym. Bez gallyutsinatsij.

Klyuch k borbe s vydumkami modeli.

Context Precision (Tochnost konteksta)

Kachestvo najdennoj informatsii.

Ne tot fragment -> nevernyj otvet

dazhe u umnoj modeli.

3. LLM-as-a-Judge + Cheklist

LLM-as-a-Judge:

Silnaya model proveryaet slabuyu.

Vhod: vopros + otvet + kontekst

Vyvod: verdikt po 3 stolpam

Cheklist #1 - Gallyutsinatsii:

1. Termin: dostovernost/obosnovannost

2. RAG ogranichivaet model dannymi

3. LLM-as-a-Judge avtomatiziruet

4. Izmeryaem v tsifrah, ne na glazok

Cheklist #2 - Obshchee ponimanie:

1. Determinizm vs Veroyatnost

2. Analogiya dvigatel vs avtomobil

3. Freymvork 3 stolpov

4. Vyvod: smysl, a ne sovpadenie slov

Kratkaya shpargalka dlya finalnoj podgotovki:

1. Fokus na sisteme, a ne na modeli
2. Myslim veroyatnostyami
3. Ispolzuem freymvork iz 3 stolpov
4. Znaem, kak avtomatizirovat otsenku (LLM-as-a-Judge)
5. Rol QA Engineer stala strategicheskoy